Livrable CR4 : Entraînement et Analyse

PROJET TRAITEMENT D'IMAGES

Sujet 1 : Détection des maladies des plantes

Membres du groupe :

Fadhloun Youssef
Jammoussi Ahmed
Sallemi Yassine
Bahri Mouhib
Ben Hassine Mohamed Taher

Semaine 4 - 20/04/2026

Sommaire

1. Introduction et Rappel des Objectifs 3
2. Configuration Expérimentale de Base 3
3. Stratégie d'Expérimentation 3
4. Résultats et Courbes d'Apprentissage 4
   4.1. Tableau Synthétique des Performances 4
   4.2. Visualisation des Courbes (TensorBoard) 4
5. Analyse Scientifique et Interprétation 6
   5.1. L'impact de la Régularisation (Meilleur Score) 6
   5.2. Le coût de l'Apprentissage Lent 6
   5.3. La victoire de MobileNetV2 pour le cas d'usage final 6
6. Conclusion et Perspectives (Préparation du CR5) 6

1. Introduction et Rappel des Objectifs

Suite à la conception de notre architecture détaillée dans le CR3, l'objectif de cette quatrième phase est de procéder à l'entraînement effectif de nos modèles d'apprentissage profond. Afin de garantir un modèle robuste et adapté à notre problématique (détection sur application mobile), nous avons mis en place une campagne d'expérimentation comparant plusieurs stratégies d'optimisation (ajustement du **Learning Rate**, gestion du déséquilibre des classes) et d'architectures (ResNet50 vs MobileNetV2).

2. Configuration Expérimentale de Base

Pour l'ensemble de nos expériences, le pipeline de données et les conditions matérielles ont été standardisés :

- **Dataset :** PlantVillage (38 classes).
- **Répartition des données :** 80% pour l'entraînement (Train), 20% pour la validation (Val).
- **Prétraitement et Augmentation (Train) :** Recadrage aléatoire (224x224), miroirs horizontaux et verticaux, normalisation ImageNet.
- **Optimiseur de base :** Adam.
- **Callbacks implémentés :**
  - `EarlyStopping` : Arrêt anticipé avec une patience de 6 époques pour éviter le surapprentissage (overfitting).
  - `ReduceLROnPlateau` : Réduction dynamique du taux d'apprentissage lorsque la perte de validation stagne.

3. Stratégie d'Expérimentation

Pour comprendre et optimiser le comportement de notre réseau, nous avons lancé 6 entraînements distincts :

1. **Expérience 1 (Baseline Optimisée) :** ResNet50 avec un Learning Rate (LR) de $10^{\{-4\}}$ et nos callbacks.
2. **Expérience 2 (Class Weights) :** ResNet50 avec calcul des poids par classe (pénalisation des erreurs sur les classes minoritaires) pour contrer le déséquilibre du dataset identifié lors du CR2.

3. **Expérience 3 (Low LR) :** ResNet50 avec un LR réduit à $10^{\{-5\}}$ pour étudier la stabilité de la convergence.
4. **Expérience 4 (MobileNetV2) :** Changement d'architecture vers un modèle léger (MobileNetV2) adapté aux contraintes matérielles d'un smartphone.
5. **Exp 5 (SGD) :** Changement d'optimiseur (SGD au lieu de Adam).
6. **Exp 6 (Weight Decay) :** ResNet50 avec régularisation L2 pour maximiser la généralisation.

4. Résultats et Courbes d'Apprentissage

4.1. Tableau Synthétique des Performances

Toutes les expériences ont été gérées par l'Early Stopping. Le nombre d'époques nécessaires avant convergence a fortement varié selon la stratégie (de 8 à 21 époques), confirmant l'utilité de cet arrêt dynamique pour éviter le surapprentissage ou un temps de calcul inutile.

Expérience	Modèle	Époques	Précision Val	Temps total
Baseline	ResNet50	9	99.39%	41.89 min
Exp 1 (Scheduler)	ResNet50	8	99.74%	38.34 min
Exp 2 (Class Weights)	ResNet50	14	99.81%	1.08 h
Exp 3 (LR = $10^{\{-5\}}$)	ResNet50	21	99.59%	1.61 h
Exp 4 (MobileNetV2)	MobileNetV2	18	99.67%	36.34 min
Exp 5 (SGD)	ResNet50	20	99.32%	1.51 h
Exp 6 (Weight Decay)	ResNet50	17	99.83%	1.31 h

4.2. Visualisation des Courbes (TensorBoard)

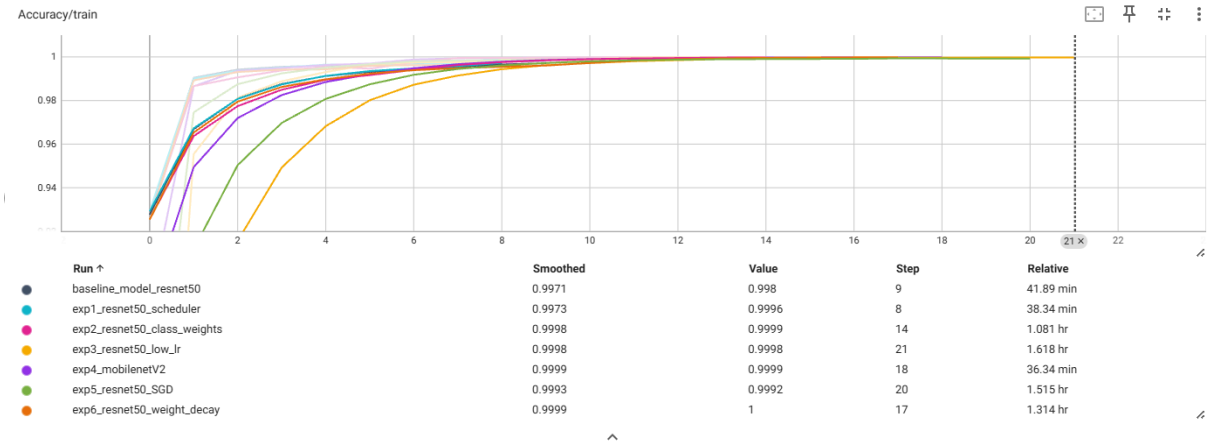

Fig. 1. – Évolution de la précision (Accuracy) sur le jeu d'entraînement pour les différentes configurations.

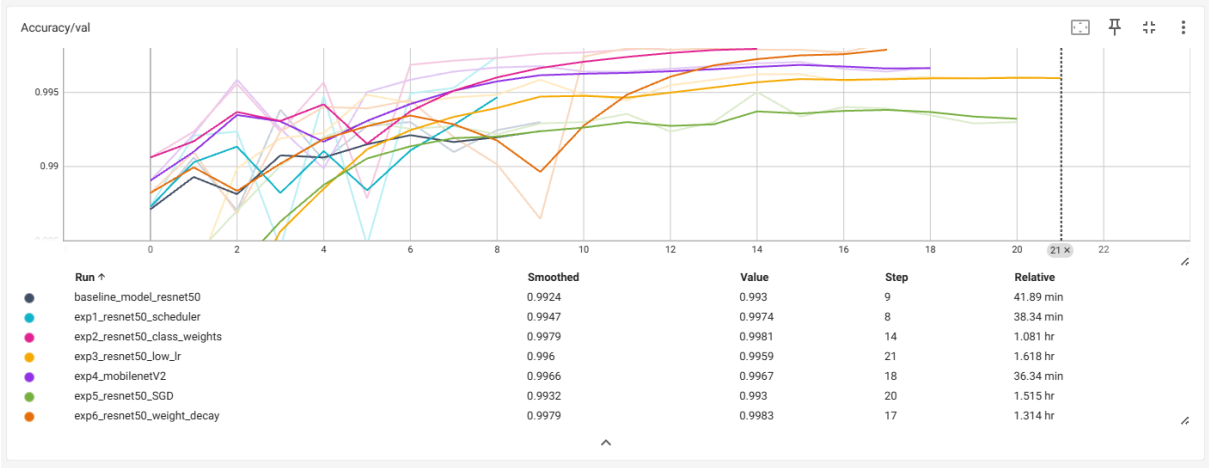

Fig. 2. – Évolution de la précision (Accuracy) sur le jeu de validationpour les différentes configurations.

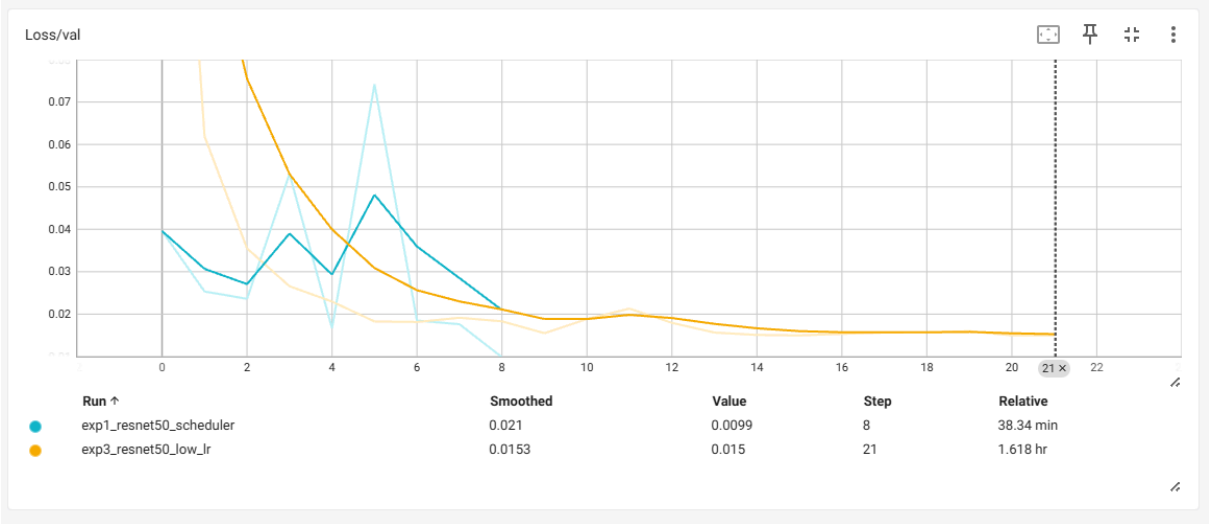

Fig. 3. – Comparaison de la stabilité de la perte (Loss) entre un taux d'apprentissage standard ($10^{\{-4\}}$) et réduit ($10^{\{-5\}}$).

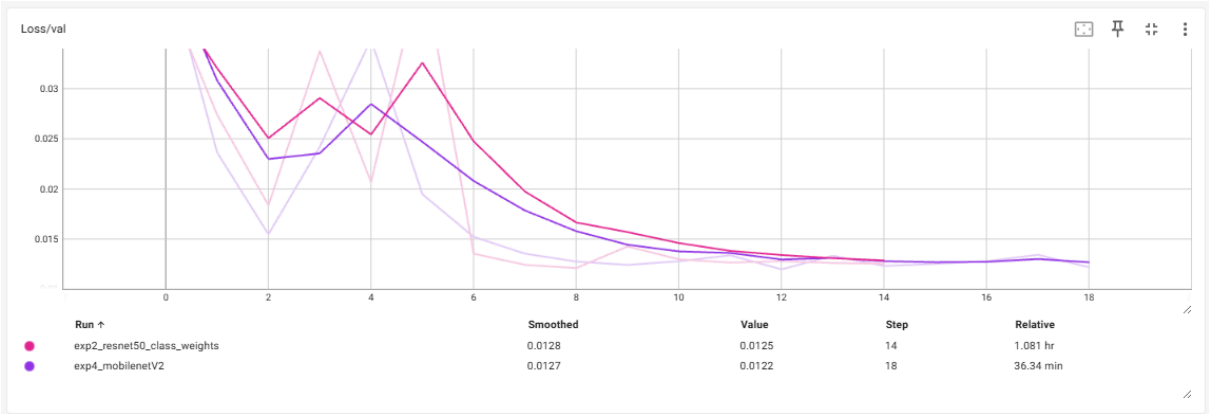

Fig. 4. – Comparaison de la convergence entre ResNet50 et MobileNetV2.

5. Analyse Scientifique et Interprétation

L'analyse des métriques nous permet de tirer trois conclusions majeures :

5.1. L'impact de la Régularisation (Meilleur Score)

L'Expérience 6 (Weight Decay) a obtenu la meilleure précision de toute notre campagne (**99.83%**). Cela prouve qu'en appliquant une pénalité sur les poids du réseau (régularisation L2), le modèle évite le surapprentissage et généralise presque parfaitement sur les données de validation. De même, l'intégration des poids de classes (Expérience 2) a permis d'atteindre **99.81%**, confirmant l'importance de traiter le déséquilibre des données.

5.2. Le coût de l'Apprentissage Lent

Les expériences 3 (LR = $10^{\{-5\}}$) et 5 (optimiseur SGD) ont nécessité beaucoup plus d'époques pour converger (respectivement 21 et 20 époques), allongeant le temps d'entraînement à plus d'une heure et demie. À l'inverse, l'Expérience 1 avec Adam et un LR adaptatif a atteint 99.74% en seulement 8 époques (38 minutes). Adam reste donc le choix le plus efficient pour ce dataset.

5.3. La victoire de MobileNetV2 pour le cas d'usage final

C'est le résultat le plus décisif pour notre projet. MobileNetV2 (Expérience 4) a réussi à effectuer **18 époques en seulement 36 minutes** (soit environ 2 minutes par époque, contre plus de 4,5 minutes pour ResNet50). Tout en étant beaucoup plus rapide à entraîner et beaucoup plus léger en termes de taille de fichier, il a maintenu une précision exceptionnelle de **99.67%**. Étant donné notre objectif de déployer cette solution sur l'appareil mobile d'un agriculteur, MobileNetV2 s'impose sans conteste comme l'architecture optimale.

6. Conclusion et Perspectives (Préparation du CR5)

Cette phase d'entraînement est un franc succès. Nous avons dépassé les 99.5% de précision, exploré l'impact de plusieurs hyperparamètres de manière rigoureuse, et identifié l'architecture la plus pertinente pour notre application (MobileNetV2).

Pour la semaine prochaine (CR5), nous procéderons à l'évaluation approfondie du modèle sélectionné. Nous générerons une matrice de confusion complète et analyserons la Précision et le Rappel (F1-Score) classe par classe pour vérifier le comportement de l'IA sur les maladies les plus rares ou les plus complexes visuellement.