Livrable CR5 : évaluation détaillée et généralisation

PROJET TRAITEMENT D'IMAGES

Sujet 1 : Détection des maladies des plantes

Membres du groupe :

Fadhloun Youssef

Jammoussi Ahmed

Sallemi Yassine

Bahri Mouhib

Ben Hassine Mohamed Taher

Semaine 5 - 28/04/2026

Sommaire

1. Introduction générale et contexte du CR5 . . . 3
2. Méthodologie générale du CR5 . . . 3
3. Référentiel expérimental et données utilisées . . . 4
4. I. Analyse détaillée **avant la généralisation** : performance sur PlantVillage . . . 4
   - 4.1. Résumé global des performances PlantVillage . . . 4
   - 4.2. Répartition détaillée par classe sur PlantVillage . . . 5
   - 4.3. Quelques classes déjé trés proches du maximum . . . 6
   - 4.4. Matrice de confusion PlantVillage . . . 7
   - 4.5. Analyse des erreurs restantes sur PlantVillage . . . 7
   - 4.6. Interprétation scientifique de la phase PlantVillage . . . 8
5. II. Préparation à la généralisation : correspondance entre PlantDoc et PlantVillage . . . 8
   - 5.1. Stratégie de mapping des classes . . . 8
   - 5.2. Tableau détaillé du mapping PlantDoc ? PlantVillage . . . 8
6. III. Analyse détaillée **aprés la généralisation** : test sur PlantDoc . . . 10
   - 6.1. Résumé global des performances sur PlantDoc . . . 10
   - 6.2. Performance détaillée classe par classe sur PlantDoc . . . 10
   - 6.3. Classes les plus performantes aprés généralisation . . . 12
   - 6.4. Classes les plus faibles aprés généralisation . . . 12
   - 6.5. Matrice de confusion de la généralisation . . . 12
   - 6.6. Lecture des erreurs sur PlantDoc . . . 13
   - 6.7. Analyse de la confiance sur PlantDoc . . . 14
7. IV. Interprétation de la généralisation et du **domain shift** . . . 14
   - 7.1. Ce que les résultats disent réellement . . . 14
8. V. Synthése comparative : avant et aprés généralisation . . . 15
9. VI. Conclusion du CR5 et perspectives . . . 15

1. Introduction générale et contexte du CR5

Aprés la phase d'entraénement et d'optimisation présentée dans le CR4, ce cinquiéme compte rendu a pour objectif d'étudier le comportement réel du modéle de détection des maladies des plantes sur deux niveaux complémentaires :

- **avant la généralisation** : évaluation approfondie sur le jeu de validation du dataset **PlantVillage** ;
- **aprés la généralisation** : test du méme modéle sur le dataset externe **PlantDoc**, afin de mesurer sa capacité à transférer ses connaissances vers un contexte plus réaliste et plus difficile.

Le point central de ce livrable est donc la notion de **généralisation**. Un modéle peut obtenir une précision presque parfaite sur les données qu'il a vues pendant l'entraénement, tout en échouant sur des images nouvelles qui changent simplement d'éclairage, de fond, de cadrage ou de variété de plante. Le CR5 vise donc à répondre à la question suivante : **le modéle apprend-il réellement la maladie, ou seulement les caractéristiques du dataset PlantVillage ?** Cette analyse est fondamentale pour notre projet, car la finalité n'est pas seulement d'avoir un bon score sur un jeu de données académique, mais de construire un systéme capable de fonctionner dans des conditions plus proches du terrain.

2. Méthodologie générale du CR5

Pour mener cette évaluation, nous avons suivi une logique en trois étapes :

1. **Vérification du modéle sur PlantVillage** : calcul des métriques par classe, de la matrice de confusion et des confidences.
2. **Construction d'un pont entre PlantDoc et PlantVillage** : création d'un mapping sémantique entre les noms de classes.
3. **évaluation croisée sur PlantDoc** : analyse des performances, des confusions et de la confiance sur un dataset jamais vu pendant l'entraénement.

Les résultats ont ensuite été résumés dans plusieurs fichiers markdown et CSV, puis consolidés dans ce rapport Typst de maniére structurée et détaillée.

3. Référentiel expérimental et données utilisées

Avant d'entrer dans les résultats, il est utile de rappeler les deux univers de données utilisés dans ce CR5.

Dataset	Réle dans le CR5	Nombre de classes	Observations principales
PlantVillage	Validation interne	38	Images propres, fond contrélé, trés bonnes performances attendues
PlantDoc	Généralisation externe	28 bruts / 27 mappés	Images de terrain, fond naturel, variabilité importante

Le tableau précédent met en évidence la différence de nature entre les deux datasets. **PlantVillage** sert de base de référence, alors que **PlantDoc** permet de tester la robustesse réelle du modéle.

4. I. Analyse détaillée avant la généralisation : performance sur PlantVillage

Cette premiére partie correspond à l'évaluation la plus favorable du modéle, puisque les images de validation proviennent du méme univers de données que celui utilisé pour l'entraénement. Cela permet de mesurer la qualité du modéle dans des conditions idéales et de vérifier s'il a bien appris les classes de maniére discriminante.

4.1. Résumé global des performances PlantVillage

Indicateur	Valeur
Images évaluées	10?861
Images correctes	10?794
Images incorrectes	67
Accuracy globale	99.38%
Confiance moyenne des bonnes prédictions	0.9968
Confiance moyenne des erreurs	0.8138
Classes parfaites (F1 = 1.0)	18
Classes avec F1 ? 0.95	36

Les chiffres ci-dessus montrent un comportement quasi parfait : plus de 10 700 images correctement classées sur 10 861, soit une précision globale de **99.38%**. Le taux d'erreur est extrémement faible (**0.62%**), ce qui confirme que le réseau de type ResNet50 a appris à reconnaétre avec une grande fiabilité les maladies et états sains présents dans PlantVillage.

4.2. Répartition détaillée par classe sur PlantVillage

Le tableau ci-dessous reprend les métriques classe par classe : précision, rappel, F1-score et support. Cette vision est essentielle, car un score global trés élevé peut masquer quelques classes plus difficiles.

Classe PlantVillage	**Précision**	**Rappel**	**F1-score**	**Support**
AppleCedar_apple_rust	100.00%	100.00%	100.00%	49
Applehealthy	100.00%	100.00%	100.00%	359
Blueberryhealthy	100.00%	100.00%	100.00%	290
Cherry*(including_sour)*Powdery_mildew	100.00%	100.00%	100.00%	249
Cherry*(including_sour)*healthy	100.00%	100.00%	100.00%	166
Corn*(maize)*healthy	100.00%	100.00%	100.00%	215
GrapeBlack_rot	100.00%	100.00%	100.00%	233
GrapeEsca(Black_Measles)	100.00%	100.00%	100.00%	279
Grape*Leaf_blight*(Isariopsis_Leaf_Spot)	100.00%	100.00%	100.00%	224
Grapehealthy	100.00%	100.00%	100.00%	71
Orange*Haunglongbing*(Citrus_greening)	100.00%	100.00%	100.00%	1104
Pepper,*bell*healthy	100.00%	100.00%	100.00%	307
PotatoEarly_blight	100.00%	100.00%	100.00%	205
Potatohealthy	100.00%	100.00%	100.00%	31
Raspberryhealthy	100.00%	100.00%	100.00%	79
Soybeanhealthy	100.00%	100.00%	100.00%	1009
SquashPowdery_mildew	100.00%	100.00%	100.00%	354
Strawberryhealthy	100.00%	100.00%	100.00%	94
TomatoTomato_Yellow_Leaf_Curl_Virus	100.00%	99.63%	99.81%	1079
Pepper,*bell*Bacterial_spot	99.52%	100.00%	99.76%	207
StrawberryLeaf_scorch	99.51%	100.00%	99.76%	204
TomatoLeaf_Mold	100.00%	99.51%	99.76%	205
Tomatohealthy	100.00%	99.40%	99.70%	336
TomatoBacterial_spot	99.51%	99.76%	99.63%	409
PeachBacterial_spot	99.81%	99.43%	99.62%	522
AppleBlack_rot	100.00%	99.17%	99.58%	120
TomatoSeptoria_leaf_spot	99.16%	99.72%	99.44%	356

TomatoSpider_mites Two-spotted_spider_mite	99.38%	99.38%	99.38%	321
Peachhealthy	98.57%	100.00%	99.28%	69
AppleApple_scab	98.48%	100.00%	99.24%	130
TomatoTomato_mosaic_virus	98.36%	100.00%	99.17%	60
TomatoTarget_Spot	97.93%	99.58%	98.75%	238
PotatoLate_blight	100.00%	97.44%	98.70%	195
TomatoEarly_blight	98.16%	99.07%	98.61%	215
Corn*(maize)*Northern_Leaf_Blight	95.10%	97.00%	96.04%	200
TomatoLate_blight	98.54%	92.35%	95.35%	366
Corn*(maize)*Common_rust	90.36%	100.00%	94.94%	225
Corn*(maize)*Cercospora_leaf_spot Gray_leaf_spot	93.83%	88.37%	91.02%	86

Les classes parfaitement maétrisées sont nombreuses. Les 18 classes suivantes ont toutes atteint un F1-score de 1.0 :

`Apple___Cedar_apple_rust`	`Orange__Haunglongbing_(Citrus_greening)`
`Apple___healthy`	`Pepper,_bell___healthy`
`Blueberry___healthy`	`Potato___Early_blight`
`Cherry__Powdery_mildew`	`Potato___healthy`
`Cherry___healthy`	`Raspberry___healthy`
`Corn_(maize)___healthy`	`Soybean___healthy`
`Grape___Black_rot`	`Squash___Powdery_mildew`
`Grape___Esca_(Black_Measles)`	`Strawberry___healthy`
`Grape___Leaf_blight`	`Grape___healthy`

4.3. Quelques classes déjé trés proches du maximum

Classe	**Précision**	**Rappel**	**F1**
TomatoTomato_Yellow_Leaf_Curl_Virus	100.00%	99.63%	99.81%
TomatoLeaf_Mold	100.00%	99.51%	99.76%
Tomatohealthy	100.00%	99.40%	99.70%
TomatoBacterial_spot	99.51%	99.76%	99.63%
PeachBacterial_spot	99.81%	99.43%	99.62%
Corn*(maize)*Northern_Leaf_Blight	95.10%	97.00%	96.04%
TomatoLate_blight	98.54%	92.35%	95.35%
Corn*(maize)*Common_rust	90.36%	100.00%	94.94%
Corn*(maize)*Cercospora_leaf_spot Gray_leaf_spot	93.83%	88.37%	91.02%

4.4. Matrice de confusion PlantVillage

La figure suivante doit étre insérée à cet emplacement dans la version finale du document. Elle permet d'identifier visuellement les confusions résiduelles entre classes trés proches.

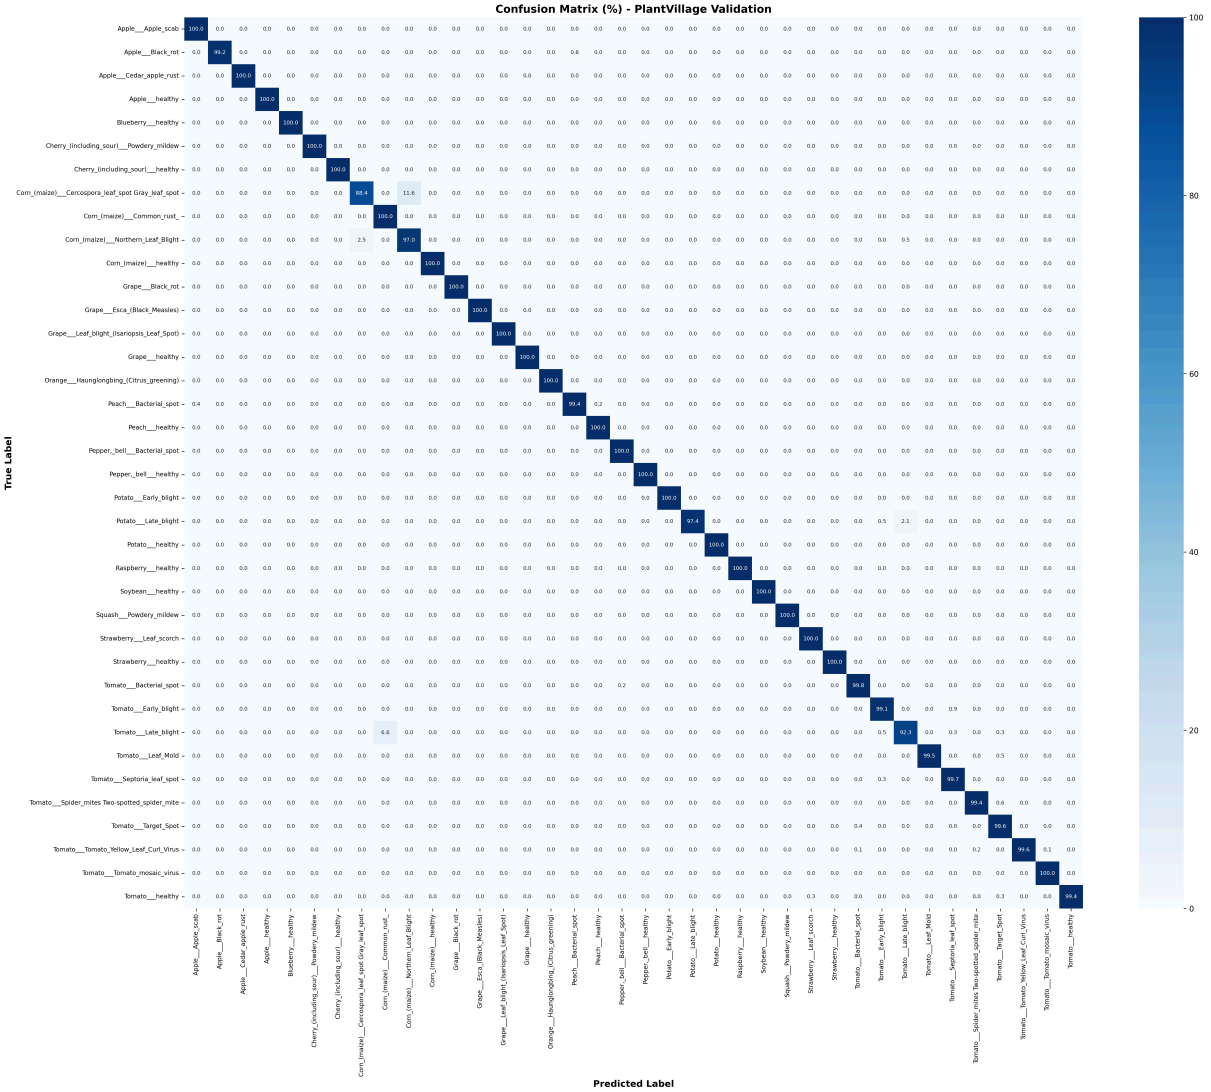

Fig. 1. – Matrice de confusion du modéle sur **PlantVillage** (version détaillée)

4.5. Analyse des erreurs restantes sur PlantVillage

Méme si les performances sont excellentes, le modéle n'est pas absolument parfait. Nous avons identifié **67 erreurs** seulement. La confiance moyenne des prédictions correctes est de **0.9968**, alors que celle des erreurs est de **0.8138**. Cela signifie que le modéle peut se tromper tout en restant assez confiant. Les principaux motifs d'erreur sont :

- `Tomato___Late_blight` : 28 erreurs, souvent confondu avec `Corn_(maize)___Common_rust_`.
- `Corn_(maize)___Northern_Leaf_Blight` : 6 erreurs, souvent confondu avec `Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot`.

- `Potato___Late_blight` : 5 erreurs, souvent confondu avec `Tomato___Late_blight`.
- 47.8% des erreurs ont une confiance supérieure à 0.9, ce qui montre que les erreurs les plus difficiles sont aussi les plus confiantes.

Ces erreurs s'expliquent par la similarité visuelle entre certaines maladies et par le fait que certaines pathologies présentent des symptémes proches sur des plantes différentes.

4.6. Interprétation scientifique de la phase PlantVillage

La conclusion scientifique de cette premiére phase est simple : le modéle a **trés bien appris** le dataset PlantVillage. Le score élevé ne doit pas étre interprété comme un hasard ; il montre que l'architecture et les réglages retenus sont capables d'exploiter les caractéristiques visuelles du jeu de données. Cependant, la suite du CR5 démontre que cette excellente performance interne ne garantit pas une robustesse similaire sur des images plus réalistes.

5. II. Préparation à la généralisation : correspondance entre PlantDoc et PlantVillage

PlantDoc ne reprend pas exactement les mémes noms de classes que PlantVillage. Il a donc fallu établir une correspondance entre les dossiers de classes des deux datasets. Cette étape est capitale : sans elle, le modéle ne pourrait pas étre évalué proprement sur les nouvelles images.

5.1. Stratégie de mapping des classes

La correspondance a été construite à partir d'une logique de **fuzzy matching** (comparaison approximative des chaénes de caractéres) et d'une validation manuelle des correspondances les plus plausibles. L'idée est de relier des classes qui décrivent, en substance, la méme maladie mais avec une formulation différente. Par exemple :

- `Tomato leaf bacterial spot` ? `Tomato___Bacterial_spot`
- `Potato leaf late blight` ? `Potato___Late_blight`
- `Corn Gray leaf spot` ? `Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot`

5.2. Tableau détaillé du mapping PlantDoc ? PlantVillage

Le tableau suivant présente toutes les correspondances retenues, avec leur niveau de confiance. Un niveau élevé signifie que la correspondance entre les deux classes est trés probable.

Classe PlantDoc	Classe PlantVillage cible	Confiance	Statut

Apple Scab Leaf	AppleApple_scab	0.864	?
Apple leaf	AppleApple_scab	0.571	?
Apple rust leaf	AppleApple_scab	0.495	?
Bell_pepper leaf	Pepper,*bell*healthy	0.474	?
Bell_pepper leaf spot	Pepper,*bell*Bacterial_spot	0.520	?
Blueberry leaf	Blueberryhealthy	0.667	?
Cherry leaf	StrawberryLeaf_scorch	0.457	?
Corn Gray leaf spot	Corn*(maize)*Cercospora_leaf_spot Gray_leaf_spot	0.493	?
Corn leaf blight	Corn*(maize)*Northern_Leaf_Blight	0.549	?
Peach leaf	Peachhealthy	0.560	?
Potato leaf early blight	PotatoEarly_blight	0.927	?
Potato leaf late blight	PotatoLate_blight	0.923	?
Raspberry leaf	Raspberryhealthy	0.667	?
Soyabean leaf	Soybeanhealthy	0.600	?
Squash Powdery mildew leaf	SquashPowdery_mildew	0.933	?
Strawberry leaf	StrawberryLeaf_scorch	0.718	?
Tomato Early blight leaf	TomatoEarly_blight	0.927	?
Tomato Septoria leaf spot	TomatoSeptoria_leaf_spot	0.954	?
Tomato leaf	TomatoLeaf_Mold	0.690	?
Tomato leaf bacterial spot	TomatoBacterial_spot	0.933	?
Tomato leaf late blight	TomatoLate_blight	0.923	?
Tomato leaf mosaic virus	TomatoTomato_mosaic_virus	0.692	?
Tomato leaf yellow virus	TomatoTomato_Yellow_Leaf_Curl_Virus	0.581	?
Tomato mold leaf	TomatoLeaf_Mold	0.588	?
Tomato two spotted spider mites leaf	TomatoSpider_mites Two-spotted_spider_mite	0.667	?
grape leaf	Grapehealthy	0.560	?
grape leaf black rot	GrapeBlack_rot	0.911	?

Les correspondances les plus fiables concernent notamment `Tomato Septoria leaf spot`, `Squash Powdery mildew leaf`, `Tomato leaf bacterial spot`, `Tomato Early blight leaf`, `Potato leaf early blight`, `Potato leaf late blight` et `grape leaf black rot`. à l'inverse, certaines associations sont plus fragiles, comme `Bell_pepper leaf` ou `Apple rust leaf`, car le nom de la classe PlantDoc reste plus générique ou ambigu. La qualité du mapping est importante, car elle influence directement la qualité de l'interprétation lors de la généralisation.

6. III. Analyse détaillée aprés la généralisation : test sur PlantDoc

Une fois le mapping construit, nous avons évalué le méme modéle sur le dataset PlantDoc. C'est ici que l'on observe le véritable comportement de généralisation.

6.1. Résumé global des performances sur PlantDoc

Indicateur	Valeur
Accuracy globale	19.61%
Précision macro	18%
Rappel macro	12%
F1 macro	12%
Précision pondérée	32%
Rappel pondéré	20%
F1 pondérée	21%
Confiance moyenne	0.7159
Confiance minimale	0.1390
Confiance maximale	1.0000

Le contraste est frappant : la précision chute à **19.61%**, alors que la confiance moyenne reste élevée (**0.7159**). Le modéle ne devient donc pas simplement incertain ; il reste convaincu de ses réponses, mais ses réponses sont souvent incorrectes. C'est un indicateur fort de **domain shift**.

6.2. Performance détaillée classe par classe sur PlantDoc

Le tableau suivant reprend les métriques de performance pour chaque classe du point de vue du référentiel PlantVillage. Les colonnes `pd_classes` indiquent le nom PlantDoc associé à chaque classe quand une correspondance a pu étre établie.

Classe PlantVillage	Classe PlantDoc associée	Précision	Rappel	F1-score	Support
CornNorthern_Leaf_Blight	Corn leaf blight	65.98%	35.75%	46.38%	179
CornCercospora_leaf_spot Gray_leaf_spot	Corn Gray leaf spot	37.21%	50.00%	42.67%	64
SquashPowdery_mildew	Squash Powdery mildew leaf	37.58%	45.16%	41.03%	124
Pepper,*bell*healthy	Bell_pepper leaf	40.48%	32.08%	35.79%	53

Raspberryhealthy	Raspberry leaf	85.71%	16.07%	27.07%	112
Grapehealthy	grape leaf	34.29%	21.05%	26.09%	57
TomatoLate_blight	Tomato leaf late blight	19.12%	38.61%	25.57%	101
Pepper,*bell*Bacterial_spot	Bell_pepper leaf spot	22.08%	27.42%	24.46%	62
TomatoEarly_blight	Tomato Early blight leaf	19.26%	32.91%	24.30%	79
PotatoEarly_blight	Potato leaf early blight	19.35%	27.52%	22.73%	109
GrapeBlack_rot	grape leaf black rot	27.78%	17.86%	21.74%	56
TomatoSeptoria_leaf_spot	Tomato Septoria leaf spot	38.18%	15.11%	21.65%	139
Blueberryhealthy	Blueberry leaf	20.59%	19.81%	20.19%	106
PotatoLate_blight	Potato leaf late blight	42.86%	9.28%	15.25%	97
AppleApple_scab	Apple Scab Leaf, Apple leaf, Apple rust leaf	19.57%	11.07%	14.14%	244
Soybeanhealthy	Soyabean leaf	50.00%	5.26%	9.52%	57
StrawberryLeaf_scorch	Cherry leaf, Strawberry leaf	6.27%	12.59%	8.37%	135
TomatoLeaf_Mold	Tomato leaf, Tomato mold leaf	40.00%	4.29%	7.74%	140
TomatoBacterial_spot	Tomato leaf bacterial spot	16.67%	0.99%	1.87%	101
AppleBlack_rot	N/A	0.00%	0.00%	0.00%	0
AppleCedar_apple_rust	N/A	0.00%	0.00%	0.00%	0
Applehealthy	N/A	0.00%	0.00%	0.00%	0
Cherry*(including_sour)*Powdery_mildew	N/A	0.00%	0.00%	0.00%	0
Cherry*(including_sour)*healthy	N/A	0.00%	0.00%	0.00%	0
Corn*(maize)*Common_rust	N/A	0.00%	0.00%	0.00%	0
Corn*(maize)*healthy	N/A	0.00%	0.00%	0.00%	0
Grape*Esca*(Black_Measles)	N/A	0.00%	0.00%	0.00%	0
Grape*Leaf_blight*(Isariopsis_Leaf_Spot)	N/A	0.00%	0.00%	0.00%	0
Orange*Haunglongbing*(Citrus_greening)	N/A	0.00%	0.00%	0.00%	0
PeachBacterial_spot	N/A	0.00%	0.00%	0.00%	0
Peachhealthy	Peach leaf	0.00%	0.00%	0.00%	103
Potatohealthy	N/A	0.00%	0.00%	0.00%	0
Strawberryhealthy	N/A	0.00%	0.00%	0.00%	0
TomatoSpider_mites Two-spotted_spider_mite	Tomato two spotted spider mites leaf	0.00%	0.00%	0.00%	2
TomatoTarget_Spot	N/A	0.00%	0.00%	0.00%	0
TomatoTomato_mosaic_virus	Tomato leaf mosaic virus	0.00%	0.00%	0.00%	44
Tomatohealthy	N/A	0.00%	0.00%	0.00%	0

6.3. Classes les plus performantes aprés généralisation

Les meilleures classes en termes de F1-score sont :

- `Corn_(maize)___Northern_Leaf_Blight` ? **F1 = 46.38%**
- `Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot` ? **F1 = 42.67%**
- `Squash___Powdery_mildew` ? **F1 = 41.03%**
- `Pepper,_bell___healthy` ? **F1 = 35.79%**
- `Raspberry___healthy` ? **F1 = 27.07%**

Ces classes sont celles qui transforment le mieux leurs caractéristiques visuelles d'un dataset à l'autre. En général, les maladies trés marquées structurellement résistent mieux au changement de domaine.

6.4. Classes les plus faibles aprés généralisation

Les classes les plus faibles incluent :

- `Tomato___Bacterial_spot` ? **F1 = 1.87%**
- `Tomato___Leaf_Mold` ? **F1 = 7.74%**
- `Soybean___healthy` ? **F1 = 9.52%**
- `Apple___Apple_scab` ? **F1 = 14.14%**
- `Potato___Late_blight` ? **F1 = 15.25%**

Dans plusieurs cas, la précision ou le rappel restent bas malgré une confiance élevée. Cela signifie que le modéle ne sait pas toujours distinguer correctement les symptémes dans un contexte naturel.

6.5. Matrice de confusion de la généralisation

Le second emplacement image est volontairement réservé à la matrice de confusion de l'évaluation PlantDoc. Elle permet de visualiser précisément quelles maladies sont confondues entre elles.

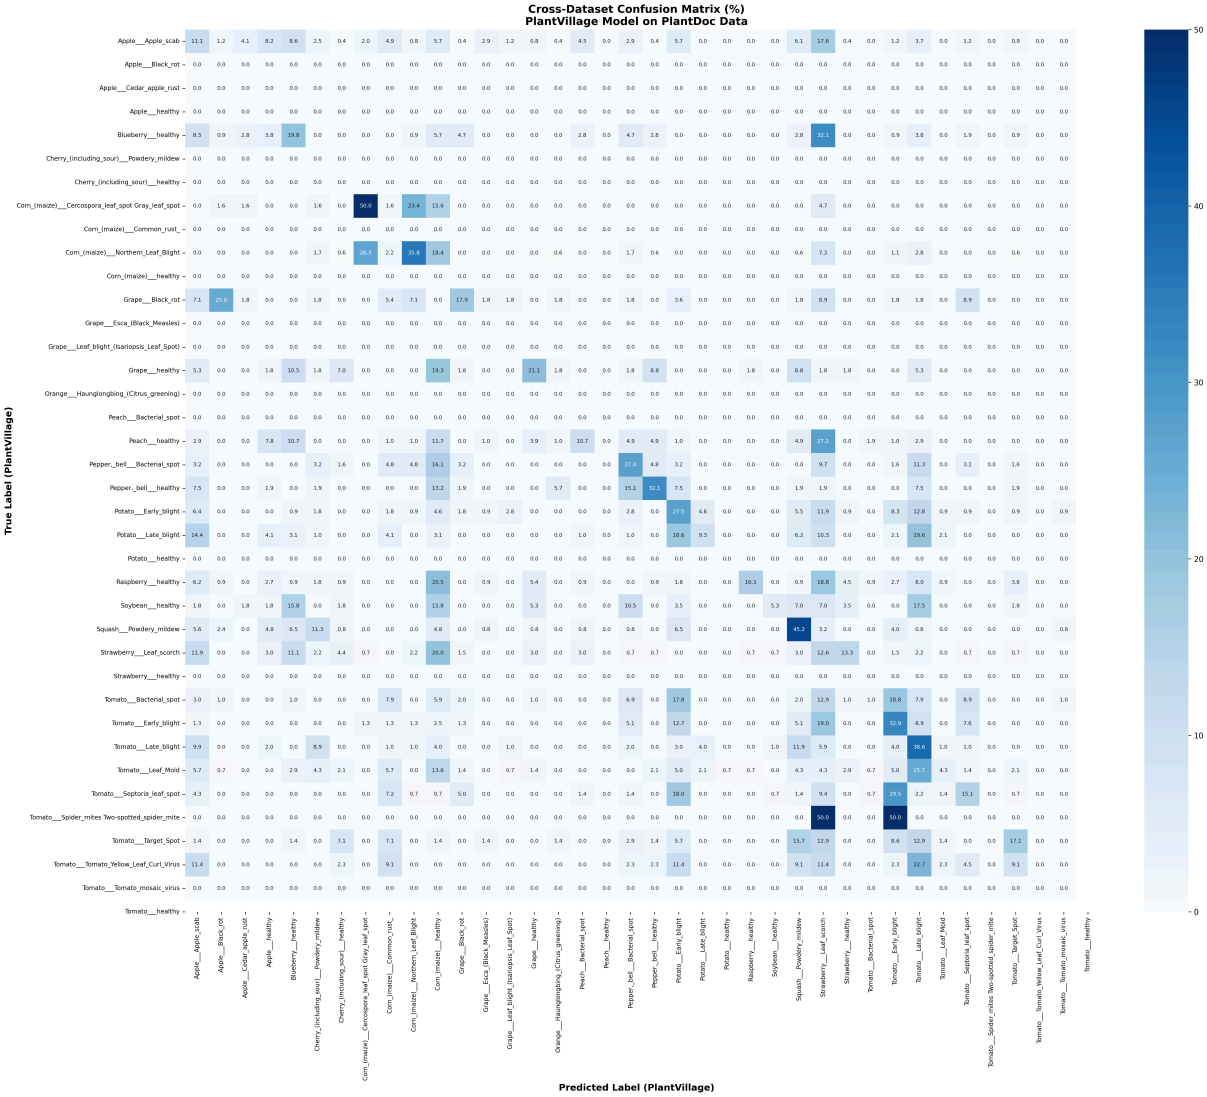

Fig. 2. – Matrice de confusion de la généralisation sur **PlantDoc**.

6.6. Lecture des erreurs sur PlantDoc

Le fichier de classification détaillée montre que certaines confusions reviennent régulièrement :

- `Tomato___Late_blight` est souvent confondu avec `Corn_(maize)___Common_rust_` ;
- `Corn_(maize)___Northern_Leaf_Blight` est souvent confondu avec `Corn_(maize)___Cercospora_leaf_spot Gray_leaf_spot` ;
- `Potato___Late_blight` est parfois confondu avec `Tomato___Late_blight` ;
- `Tomato___Early_blight` et `Tomato___Septoria_leaf_spot` se mélangent fréquemment ;
- plusieurs classes `healthy` sont parfois reconnues avec moins de stabilité en contexte extérieur.

6.7. Analyse de la confiance sur PlantDoc

La répartition de la confiance confirme le probléme de calibration : plus la confiance augmente, plus la précision s'améliore, mais le niveau de départ reste faible.

Intervalle de confiance	Nombre d'images	Part du total	Accuracy observée
0.10 ? 0.30	128	5.7%	16.41%
0.30 ? 0.50	489	21.9%	18.81%
0.50 ? 0.70	749	33.5%	20.56%
0.70 ? 0.90	739	33.1%	23.24%
0.90 ? 1.00	129	5.8%	28.68%

Ce tableau montre qu'une confiance élevée n'est pas synonyme de robustesse suffisante : méme au-dessus de 90% de confiance, la précision n'atteint qu'environ 28.68%.

7. IV. Interprétation de la généralisation et du domain shift

Le passage de 99.38% sur PlantVillage à 19.61% sur PlantDoc constitue une chute d'environ 80 points de précision. Cela ne signifie pas que le modéle est mauvais ; cela signifie surtout qu'il a appris à reconnaétre un **contexte de données** plutét qu'une réalité totalement indépendante de ce contexte. Les causes principales sont les suivantes :

- **fond** : PlantVillage présente des images plus propres et plus homogénes ;
- **lumiére** : PlantDoc contient des images de terrain avec éclairage naturel ;
- **échelle et cadrage** : les feuilles apparaissent à des tailles et angles variés ;
- **variabilité biologique** : la méme maladie peut se présenter différemment selon la plante, la variété ou le stade de développement ;
- **similarité des symptémes** : certaines maladies ont des textures trés proches, ce qui brouille la frontiére entre classes.

En d'autres termes, le modéle n'est pas seulement confronté à de nouvelles images ; il est confronté à un nouveau **monde visuel**.

7.1. Ce que les résultats disent réellement

1. Le modéle a trés bien appris à distinguer les classes de PlantVillage.
2. Il existe néanmoins un fort risque de surapprentissage au contexte du dataset.
3. Les classes à symptémes forts (comme certaines maladies du maés ou de la courge) transférent mieux.
4. Les classes plus ambigués, ou dépendantes du contexte, perdent beaucoup en performance.

5. Une généralisation robuste nécessitera au minimum du **fine-tuning** sur PlantDoc, et idéalement une stratégie de réentraénement plus large.

8. V. Synthése comparative : avant et aprés généralisation

Aspect	PlantVillage	PlantDoc	Lecture
Précision globale	99.38%	19.61%	Le modéle chute fortement hors domaine
Confiance moyenne	0.9968 (corrects) / 0.8138 (erreurs)	0.7159	Le modéle reste confiant méme lorsqu'il se trompe
Classes trés fortes	36 classes F1 ? 0.95	5 classes seulement au-dessus de 0.30	La robustesse ne se transfére pas entiérement
Type d'images	Contrélées	Naturelles / terrain	Le changement de contexte explique une grande partie de la baisse

Cette synthése montre clairement le réle de la généralisation : un bon score en environnement connu ne suffit pas à garantir un comportement fiable sur des données nouvelles.

9. VI. Conclusion du CR5 et perspectives

Le CR5 confirme deux constats complémentaires :

1. **Le modéle est excellent sur PlantVillage** : il matrise presque parfaitement le jeu de données de référence.
2. **Le modéle généralise mal vers PlantDoc** : malgré une forte confiance, la précision s'effondre en contexte réel.

Le point important à retenir est donc le suivant : nous disposons d'un modéle performant en laboratoire, mais encore insuffisamment robuste pour une utilisation réelle sans adaptation supplémentaire. Pour la suite du projet, les pistes les plus cohérentes sont :

- **fine-tuning** sur PlantDoc ;
- augmentation de données plus réaliste ;

- réentraénement mixte PlantVillage + PlantDoc ;
- ou adoption d'une architecture plus robuste à la variation de domaine.

En résumé, ce CR5 ne conclut pas seulement sur une performance chiffrée ; il montre surtout comment interpréter la différence entre **bien apprendre un dataset** et **bien généraliser à de nouvelles données**.